

Telco Customer Churn Prediction - MLOps Project Documentation

1. معرفی پروژه

این پروژه با هدف پیش‌بینی احتمال ریزش مشتریان (Customer Churn Prediction) در یک شرکت مخابراتی طراحی شده است.

در این پروژه یک Pipeline کامل یادگیری ماشین طراحی شده که شامل مراحل زیر است:

- دریافت و آماده‌سازی داده‌ها
- تحلیل و پردازش داده‌ها
- مهندسی ویژگی‌ها
- آموزش و مقایسه چند مدل یادگیری ماشین
- ارزیابی مدل‌ها
- ثبت آزمایش‌ها با MLflow
- مدیریت نسخه‌های مختلف دیتاست
- ثبت مدل نهایی در MLflow Model Registry
- ساخت Docker Image برای اجرای مدل
- فراهم کردن محیط آماده برای Inference

هدف اصلی پروژه، پیاده‌سازی یک چرخه کامل MLOps و نزدیک کردن فرآیند توسعه مدل به استانداردهای صنعتی است.

2. Dataset

دیتاست استفاده شده، دیتاست معروف:

Telco Customer Churn Dataset

است که شامل اطلاعات مشتریان یک شرکت مخابراتی است.

ویژگی‌های دیتاست شامل:

- اطلاعات جمعیتی مشتریان
- نوع قرارداد
- سرویس‌های فعال
- مدت زمان عضویت
- هزینه ماهانه
- مجموع پرداخت‌ها
- وضعیت خروج مشتری

:Target

Churn

که مشخص می‌کند مشتری شرکت را ترک کرده است یا خیر.

3. ساختار پروژه

ساختار کلی پروژه:

```
telco_churn_mlops/  
├── data/  
│   ├── raw/  
│   ├── processed/  
│   └── feature_engineered/  
├── src/  
│   ├── data_loader.py  
│   ├── preprocessing.py  
│   ├── features.py  
│   ├── train.py  
│   ├── evaluate.py  
│   └── mlflow_logger.py  
├── models/  
├── Dockerfile  
├── requirements.txt  
├── run_pipeline.py  
├── README.md  
└── mlruns/
```

4. Pipeline Architecture

Pipeline پروژه شامل مراحل زیر است:

Dataset

|

Data Loading

Data Preparation

Train / Validation / Test Split

Model Training

Cross Validation

Model Selection

Final Training

Evaluation

MLflow Tracking

Model Registry

Docker Deployment

Dataset Versioning .5

برای بررسی تاثیر مراحل مختلف آماده سازی داده، سه نسخه دیتاست ایجاد شد.

Version 1 - Raw Dataset

در این نسخه داده خام دریافت شده و preprocessing روی آن انجام می شود.

مراحل:

- حذف ستون های غیرضروری

- تبدیل نوع داده‌ها
 - مدیریت Missing Values
 - Encoding
-

Version 2 - Preprocessed Dataset

در این نسخه داده از قبل آماده شده و مستقیم وارد مرحله آموزش می‌شود.

Version 3 - Feature Engineered Dataset

در این نسخه ویژگی‌های جدید ایجاد شده‌اند.

هدف:

- افزایش قدرت مدل
 - استخراج اطلاعات بیشتر از رفتار مشتری
-

6. Machine Learning Models

چهار مدل مختلف بررسی شدند:

Logistic Regression

یک مدل خطی مناسب برای مسائل Classification.

Random Forest

مدل Ensemble بر پایه Decision Tree.

XGBoost

مدل Gradient Boosting با قدرت بالا در داده‌های جدولی.

CatBoost

مدل Gradient Boosting بهینه برای داده‌های دارای ویژگی‌های categorical.

Model Evaluation .7

معیارهای ارزیابی استفاده شده:

Accuracy

درصد پیش‌بینی‌های صحیح مدل.

Precision

از میان مشتریانی که مدل آن‌ها را Churn تشخیص داده، چند درصد واقعا Churn کرده‌اند.

Recall

از میان مشتریانی که واقعا Churn کرده‌اند، چند درصد توسط مدل شناسایی شده‌اند.

F1-score

ترکیبی از Precision و Recall.

ROC-AUC

توانایی مدل در جدا کردن دو کلاس.

Model Selection Results .8

نتایج Cross Validation:

F1 Score	Model
0.6144	Logistic Regression
0.5865	CatBoost
0.5713	XGBoost
0.5688	Random Forest

بر اساس نتایج، مدل:

Logistic Regression

به عنوان بهترین مدل انتخاب شد.

Final Model Performance .9

مدل نهایی روی Test Dataset:

Accuracy : 0.8126
Precision : 0.6765
Recall : 0.5658
F1 Score : 0.6162
ROC-AUC : 0.8588

Confusion Matrix:

```
[[700  76]
 [122 159]]
```

تفسیر:

- 700 مشتری به درستی غیرریزش تشخیص داده شدند.
- 159 مشتری به درستی ریزش تشخیص داده شدند.
- 76 مشتری False Positive بودند.
- 122 مشتری False Negative بودند.

MLflow Tracking .10

برای مدیریت آزمایش‌ها از MLflow استفاده شد.

MLflow وظایف زیر را انجام می‌دهد:

ثابت Parameters

مانند:

- Dataset Version
- Model Name

Hyperparameters •

ثبت Metrics

مانند:

- Accuracy •
- Precision •
- Recall •
- F1-score •
- ROC-AUC •

ثبت Artifact ها

شامل:

- Confusion Matrix •
- Model File •

Model Registry

مدل نهایی نسخه v3 در MLflow ثبت شده است:

TelcoChurnModel

11. Dockerization

برای اجرای مدل در محیط مستقل، پروژه Dockerized شده است.

Docker وظایف زیر را انجام می‌دهد:

- ایجاد محیط اجرای ثابت
- نصب Dependencies
- اجرای Pipeline بدون نیاز به تنظیمات دستی

ساخت Image:

```
docker build -t telco-churn-model .
```

بررسی Image:

```
docker images
```

اجرای Container:

```
docker run telco-churn-model
```

Docker Image .12

Docker Image شامل:

- Python Environment
- Required Libraries
- Source Code
- ML Pipeline

است.

با اجرای Container، مدل آموزش داده شده اجرا شده و امکان استفاده برای Prediction فراهم می‌شود.

Requirements .13

وابستگی‌های اصلی پروژه:

```
python  
pandas  
numpy  
scikit-learn  
xgboost  
catboost  
mlflow  
matplotlib
```



```
docker
```

تمام Dependency ها در فایل زیر ذخیره شده‌اند:

```
requirements.txt
```

Running Project .14

نصب Dependencies

```
pip install -r requirements.txt
```

اجرای Pipeline

```
python run_pipeline.py
```

Pipeline سه نسخه دیتاست را اجرا می‌کند:

v1

v2

v3

و بهترین مدل را ثبت می‌کند.

MLOps Workflow .15

Workflow نهایی:

```
Data
|
|
Preprocessing
|
```

```
|
Training
|
Experiment Tracking
|
Model Registry
|
|
Docker Image
|
Deployment
|
Inference
```

16. نتیجه‌گیری

در این پروژه یک سیستم کامل پیش‌بینی Churn طراحی شد که علاوه بر آموزش مدل، چرخه کامل MLOps را نیز پوشش می‌دهد.

مهم‌ترین دستاوردهای پروژه:

- مقایسه چند الگوریتم یادگیری ماشین
- انتخاب بهترین مدل بر اساس معیارهای ارزیابی
- مدیریت نسخه‌های مختلف داده
- ثبت آزمایش‌ها با MLflow
- ذخیره مدل نهایی در Model Registry
- ساخت محیط اجرای قابل انتقال با Docker

این پروژه نمونه‌ای از یک فرآیند واقعی Machine Learning در محیط Production است.